

Image2Biomass: Previsão de Biomassa de Pastagem a partir de Fotografias de Quadrats

Categoria do projeto: Regressão de imagem (com baseline tabular de metadados)

Membros da equipa: [Shuhrat Maksumov / ID: 28548], [Xavier Loreto / ID: 28648]

Plano do projeto

Enunciado do problema. Pretendemos prever a biomassa de pastagem a partir de fotografias de quadrats de campo de 70x30 cm, utilizando o conjunto de dados CSIRO Image2Biomass. Cada imagem tem cinco variáveis-alvo de regressão em gramas: matéria seca verde, morta, de trevo, GDM e total. A estimativa rigorosa da biomassa ajuda os agricultores a decidir quando e como apascentar o gado, o que torna este um problema agrícola de relevância prática. Para além da previsão, a nossa questão científica central é uma comparação de modalidades: quanto é que a imagem acrescenta relativamente a duas medições de campo de baixo custo (NDVI e altura da pastagem)?

Desafios. O conjunto de dados é pequeno (357 imagens etiquetadas), o que torna as redes profundas propensas a sobreajuste. As cinco variáveis-alvo apresentam forte assimetria à direita (assimetria 1,4-2,8) com muitos zeros (trevo ~38%), pelo que treinamos com uma transformação $\log_{1p}$. As observações estão correlacionadas por local e por espécie, pelo que uma divisão aleatória ingénua provoca fuga de informação; recorremos a validação cruzada por grupos. Por fim, o conjunto de teste oculto do Kaggle não inclui metadados, pelo que um estudo de modalidades justo deve comparar os modelos nos dados etiquetados localmente, e não na tabela de classificação.

Conjunto de dados. CSIRO Image2Biomass ([Kaggle](#)): 357 fotografias de quadrats com biomassa de referência associada, mais metadados (estado, espécie, NDVI pré-pastoreio, altura média, data). Dividimos o conjunto etiquetado com StratifiedGroupKFold por imagem, estratificado pela biomassa total agrupada em intervalos, de modo a que a CNN e o baseline tabular sejam avaliados exatamente nas mesmas partições.

Método. Construímos uma comparação em quatro níveis alinhada com a unidade curricular: (1) um baseline ingénuo pela mediana; (2) um baseline tabular com RandomForest / gradient boosting sobre os metadados (sessões 4, 7); (3) uma CNN treinada de raiz (sessão 10); e (4) aprendizagem por transferência através do ajuste fino (fine-tuning) de uma ResNet18 pré-treinada, comparada com a extração de características com a rede congelada (sessão 12). Uma aplicação Gradio publicada no Hugging Face (sessão 11) demonstra o modelo baseado apenas na imagem no cenário realista do agricultor. Todas as variáveis-alvo são modeladas no espaço $\log_{1p}$; as previsões são invertidas e limitadas a valores não negativos.

Avaliação. Reportamos um RMSE ponderado ao estilo da competição (pesos das variáveis-alvo 0,1/0,1/0,1/0,2/0,5), bem como RMSE, MAE e R2 por variável-alvo na escala original, agregados ao longo de 5 partições (média +/- desvio-padrão). Comparamos todos os modelos nas mesmas partições e analisamos onde cada modalidade tem sucesso ou falha (por exemplo, a matéria morta e o trevo são os mais difíceis a partir da imagem). O principal resultado é uma resposta quantificada à questão de saber se a imagem acrescenta valor preditivo para além das medições de campo de baixo custo.